

Análise Espacial, Estatística e Técnicas de Interpolação

Aula 1 - Módulo 2

Me. Gabriel Luan Rodrigues
Março 2026

1. **Fundamentos de Análise Espacial + Mapas de Densidade Kernel**
2. Estatística Espacial: I de Moran, LISA e Detecção de Outliers e Anomalias
3. Técnicas de Interpolação Espacial: IDW, Spline e Krigagem
4. Aulas Práticas

O "Onde" Importa: Fundamentos de Análise Espacial



"Quando o 'onde' revela o que os números sozinhos não mostram"

- Python (pandas, scipy, cartopy, PySAL) + dados Meteorológicos e Sicor
- Sabe como "ler" o espaço geográfico como fonte de informação sobre risco agrícola

Perguntas que tabelas não respondem:

1. Por que certos municípios concentram muito mais COPs que seus vizinhos, mesmo com clima e culturas semelhantes?
2. A gleba com perda por seca está numa região onde os dados meteorológicos confirmam déficit hídrico?
3. As perdas por geada se concentram espacialmente de forma coerente com o padrão conhecido (vales, áreas baixas)?
4. Existe algum padrão geográfico na atuação de determinado perito, IF ou grupo de produtores?

Primeira Lei da Geografia (Tobler, 1970) e Dependência Espacial: *"Tudo está relacionado com tudo, mas coisas próximas estão mais relacionadas que coisas distantes"*

Exemplos:

- **Clima:** fenômenos como seca e geada são regionais — afetam áreas contíguas
- **Solo e relevo:** características edáficas variam gradualmente
- **Práticas agrícolas:** produtores vizinhos adotam técnicas e calendários similares
- **Agentes econômicos:** IFs, peritos e cooperativas atuam em áreas definidas

Tipo	Descrição	Exemplo no Proagro
Positiva	Altos perto de altos; baixos perto de baixos	Seca regional → COPs agrupadas em mancha contínua
Negativa	Altos perto de baixos	Raro: Seca × Chuva Eccessiva
Ausente	Sem padrão discernível	COPs distribuídas aleatoriamente — possível alerta

Densidade de Kernel



Conceito básico (KDE em dados COP):

- Cada COP é um ponto georreferenciado no mapa.
- A densidade Kernel transforma esse conjunto de pontos em uma **superfície contínua de “intensidade”**, estimando onde os eventos se concentram mais ou menos no espaço.

Analogia da “fonte de calor”:

- Cada ponto se comporta como uma **fonte de calor**: brilho máximo no centro, esmaecendo gradualmente com a distância.
- Áreas onde várias fontes se sobrepõem ficam mais “quentes”; áreas com poucos pontos permanecem “frias”.

Hotspots (manchas quentes):

- A sobreposição de muitas COPs próximas gera **“manchas quentes” (hotspots)** — regiões de alta intensidade de ocorrências.
- Isso revela padrões de concentração que não são óbvios quando olhamos apenas para pontos isolados.

Resultado visual (mapa de calor):

- Obtemos um **mapa com gradiente de cores (frio → quente)**, em que cores frias indicam baixa intensidade e cores quentes indicam concentrações de COPs.
- Esse tipo de mapa é usado em GIS (QGIS, ArcGIS) e em análises de risco para identificar áreas críticas de forma exploratória.

“KDE (Kernel Density Estimation) transforma pontos isolados no mapa em uma superfície contínua de "calor", mostrando onde há maior concentração de ocorrências. Funciona como se cada ponto fosse uma fonte de luz que brilha intensamente no centro e vai esmaecendo conforme a distância aumenta — quando muitos pontos estão próximos, suas "auras" se sobrepõem e formam manchas quentes (hotspots), revelando visualmente padrões de agrupamento que não seriam perceptíveis olhando apenas para os pontos soltos.

$$\hat{f}(x, y) = \frac{1}{n \cdot h^2} \sum_{i=1}^n K \left(\frac{d_i}{h} \right)$$

- Em que:
 - d_i : distância entre o ponto (x, y) de avaliação e a COP i .
 - h : **bandwidth** (raio de suavização), controla o alcance da “aura” de cada ponto e o grau de suavização da superfície.
 - K : função kernel (forma da influência), com a **gaussiana** sendo uma escolha muito comum para KDE em estatística e em implementações como *gaussian_kde*.
 - n : número total de COPs usadas na estimativa.
- A intensidade em (x, y) é a **soma ponderada das influências de todas as COPs**, em que pontos mais próximos contribuem mais e pontos distantes contribuem pouco ou quase nada

- Em mapas de densidade Kernel (KDE), o **bandwidth h** controla o “raio de influência” de cada ponto e, portanto, o **nível de suavização** da superfície de calor.
- Bandwidth pequeno $\rightarrow$ alta resolução, mas mais ruído (subsuavização); bandwidth grande $\rightarrow$ padrões amplos, mas perda de detalhes (super-suavização).

Bandwidth	Efeito	Quando usar
$h \leq 10$ km (pequeno)	Alta resolução, mas ruidoso. Muitos "picos" isolados.	Escala municipal, alta densidade de pontos
$h \approx 20-30$ km (intermediário)	Equilíbrio entre detalhe e padrão regional. Recomendado para Proagro.	Escala microrregional — maioria das análises
$h \geq 50$ km (grande)	Padrões macrorregionais, mas perde detalhes locais.	Visão estadual ou interestadual

Interpretando os Parâmetros do KDE




- **Parâmetros do KDE**

- Bandwidth desejado: 25 km $\rightarrow$ 0.238°
- Desvio padrão médio dos dados: 4.191°
- Fator calculado para bw_method: 0.057
- Fator de Scott (padrão): 0.143
- Relação (desejado / Scott): 0.40x

- **Estatísticas da densidade**

- Mínimo: 0.000000
- Máximo: 0.075543
- Média: 0.000916
- Desvio padrão: 0.005606



- O primeiro número é o que **escolhemos**: um bandwidth de 25 quilômetros. Isso significa que cada COP vai "influenciar" uma área num raio de 25 km ao redor dela.
- Convertendo para graus $\rightarrow 0.238$ graus.
- É como se cada COP fosse uma mancha de tinta que cobre um círculo de 50 km de diâmetro.

Parâmetro	Valor	Significado
Bandwidth desejado	25 km $\rightarrow 0.238^\circ$	Estamos suavizando num raio de ~25 km

- O desvio padrão de 4.191 graus nos diz a dispersão **típica** dos dados — quanto, em média, os pontos se afastam do centro.
- Para ter uma ideia da extensão **total**, multiplicamos por 6 (se os dados seguem uma distribuição normal), o que dá cerca de 25 graus, ou 2.640 quilômetros.
 - Isso significa que nossas COPs se espalham por uma área que pode cobrir múltiplos estados.
- É uma base de dados com **ampla abrangência geográfica**.

Parâmetro	Valor	Interpretação
Desvio padrão médio	4.191° ~ 440 km	Dispersão típica dos pontos
Extensão total estimada	~2.640 km	Os dados cobrem uma área continental

- O algoritmo tem um fator padrão, chamado de **Scott**, que é calculado automaticamente baseado no número de pontos — no nosso caso, 0.143. Mas nós **forçamos** um fator diferente: 0.057, **para conseguir nosso bandwidth de 25 km**.
- A relação entre eles é 0.40, ou 40%. Isso significa que nosso fator é **40% do valor padrão**.
 - Nosso mapa de calor vai mostrar **muito mais detalhes locais** do que o mapa padrão.
 - O mapa padrão seria mais suavizado, mostrando apenas as grandes tendências regionais.
 - Com 40%, estamos "ampliando o zoom" nos detalhes.

Parâmetro	Valor	Interpretação
Fator calculado	0.057	O fator que implementa nosso bandwidth de 25 km
Fator de Scott (padrão)	0.143	O fator que o algoritmo usaria automaticamente
Relação	0.40x	Estamos usando 40% do fator padrão

Na prática, com essa relação de 0.40, estamos num ponto ideal: **detalhado o suficiente** para ver agrupamentos locais de COPs, mas **suave o suficiente** para não sermos enganados por ruído. Se a relação fosse maior que 1.5, o mapa ficaria muito "liso" e esconderia variações importantes. Se fosse menor que 0.2, cada par de COPs vizinhas viraria um hotspot — o mapa ficaria "peludo" e difícil de interpretar.

Portanto, esses números nos dizem que escolhemos bem: estamos destacando agrupamentos reais, não ruído aleatório.

Cenário	Relação (fator/fator_scott)	“Efeito”
Muito suave	$> 1.5x$	Perde detalhes locais, só grandes regiões
Equilibrado (nosso caso)	$0.3x - 0.7x$	Mostra agrupamentos locais sem ser ruidoso
Muito detalhado	$< 0.2x$	Ruído, cada ponto vira um pico isolado

Parâmetro	Valor	Interpretação
Raio de influência	25 km	Cada COP cobre área de um município médio
Dispersão típica	4.191° (~440 km)	Distância típica entre agrupamentos
Extensão total	~2.640 km	COPs espalhadas por vários estados
Detalhamento	40% do padrão	Estamos "ampliando" 2.5x em relação ao automático

"O bandwidth ideal não é um número absoluto — é aquele que revela os padrões relevantes para sua pergunta sem criar artefatos."

Não existe um bandwidth "certo" universal. O que é ideal para identificar municípios críticos (h pequeno) é diferente do que é ideal para ver corredores de seca regional (h grande). O importante é **entender o que cada escolha revela ou esconde**, e sempre testar múltiplas escalas antes de concluir.

Tipologias de Densidade no Proagro



Mapa da **densidade absoluta de COPs** (KDE não ponderada) para uma safra, considerando todas as COPs georreferenciadas.

- **Estratificações recomendadas:**

- Por **fenômeno**: seca, chuva excessiva, geada, granizo.
- Por **cultura**: soja, milho, café, etc.

- **Uso analítico:**

- Gerar **mapas separados por fenômeno** para a mesma safra e região.
- **Comparar hotspots de seca e de chuva** no mesmo local/período:
 - Se os hotspots coincidirem fortemente, isso sugere inconsistência, pois seca severa e chuva excessiva dificilmente explicam, ao mesmo tempo, o mesmo conjunto de perdas no mesmo intervalo espacial e temporal.

Ideia: em vez de cada COP contar “1”, cada ponto recebe um **peso** ligado a um atributo econômico, produzindo uma **KDE ponderada**.

- **Opções de ponderação (exemplos para o Proagro):**
 - **Valor de indenização** (valor pago): evidência **onde está o maior impacto financeiro** das perdas.
 - **Percentual de perda** (% de perda): destaca **onde as perdas são mais severas em termos relativos**, mesmo com poucas COPs.
 - **Área afetada** (hectares sinistrados): mostra **quanto território está comprometido** em cada região.
- **Pergunta que responde:**
 - Deixa de ser apenas “onde há mais COPs?” e passa a ser “**onde o impacto econômico e produtivo é maior?**”.

$$\text{Taxa}(x, y) = \frac{\hat{f}_{\text{COPs}}(x, y)}{\hat{f}_{\text{operações}}(x, y)}$$

- **Construção:**

- f (cops): KDE da localização das COPs (casos).
- f (operações): KDE da localização das operações de crédito (exposição).

A **taxa espacializada** é a **razão entre essas duas densidades**, análoga a superfícies de risco relativo em epidemiologia espacial.

- **Diferencia:**

- Regiões com **muitos sinistros porque têm muita produção/operações** (alto volume absoluto, mas risco esperado).
- Regiões onde a **taxa de sinistro é desproporcionalmente alta**, ou seja, **risco relativo elevado**, mesmo com poucas operações.

- **Pergunta que responde:**

- “Há muitos sinistros aqui apenas porque temos muita produção, ou porque o **risco relativo** aqui é maior do que o esperado dado o volume de operações?”

Interpretação, Limitações e Ponte para Estatística Formal



Contextualização obrigatória de todo hotspot

- **Climática:** coincide com dados meteorológicos de fenômeno adverso?
- **Agroeconômica:** reflete volume de produção ou risco real?
- **Temporal:** padrão persistente (estrutural) ou pontual (evento isolado)?

Limitações

- Mapas de calor são **exploratórios** — padrões visuais não provam nada
 - Efeito de borda: subestima densidade nos limites
 - Resultado depende do bandwidth → sempre testar múltiplas escalas
- O olho humano encontra padrões até em dados aleatórios (**pareidolia estatística**)

- A dimensão espacial é fonte de informação, não apenas atributo cadastral
- Dependência espacial (Tobler): coisas próximas são mais parecidas
- Autocorrelação positiva é o padrão esperado para fenômenos climáticos reais
- KDE: pontos → superfícies, identificar hotspots visualmente
- Bandwidth é decisivo; analisar em múltiplas escalas
- Mapas de calor são exploratórios — padrões visuais requerem confirmação estatística

Obrigado!

meteorologiageotec.derop@bcb.gov.br



LinkedIn

DÚVIDAS?



bcb.gov.br

