

Análise Espacial, Estatística e Técnicas de Interpolação

Aula 2 - Módulo 2

Me. Gabriel Luan Rodrigues
Março 2026

1. Fundamentos de Análise Espacial + Mapas de Densidade Kernel
2. **Estatística Espacial: I de Moran, LISA e Detecção de Outliers e Anomalias**
3. Técnicas de Interpolação Espacial: IDW, Spline e Krigagem
4. Aulas Práticas

AVISO!

**A PARTIR DA SEMANA QUE VEM,
MENTORIAS ÀS SEXTAS-FEIRAS DE MANHÃ
DAS 9H ÀS 12H**

Próxima Mentoria: 20/03 (sexta)

Semana 7		Seg 16/03	Ter 17/03	Qua 18/03	Qui 19/03	Sex 20/03
Março	Manhã		10:00-12:00 Mapeamento das Áreas de Risco [Prática] (1/3)	10:00-12:00 Mapeamento das Áreas de Risco [Prática] (2/3)		09:00-12:00 Atendimento Meteo
	Almoço					
	Tarde	14:00-16:00 Fundamentos (1/2)		14:00-16:00 Fundamentos (2/2)	14:30-17:30 Dados do Sicor e Impedimentos Sociais, Ambien...	14:30-17:30 Dados do Sicor e Impedimentos Sociais, Ambien...

Do Visual à Certeza Estatística




Será que o padrão que eu vejo é real? E se for, onde exatamente está?"

Na aula anterior: aprendemos a **ver** padrões com mapas de calor (KDE)

- Problema 1: o olho humano não quantifica incerteza → **pareidolia estatística**
- Problema 2: ver um hotspot no mapa não diz quais municípios específicos o formam
- Hoje vamos resolver **ambos** os problemas:
 - **I de Moran (global** "Há autocorrelação espacial? É significativa?"
 - **LISA (local:** "Onde exatamente estão os hotspots, coldspots e outliers?"

*100 moedas jogadas no chão — mesmo aleatoriamente, haverá "aglomerados" aparentes.
Precisamos de teste formal.*

Pareidolia encontramos Padrões que talvez não sejam reais




Abraham Wald 2ª Guerra Mundial

- onde aplicar fuselagem extra para proteger os aviões
- Poderia-se chegar a conclusão de que seria melhor blindar regiões com mais perfurações.
- Os dados se tratavam apenas dos aviões que retornavam à base

Supondo que a distribuição de tiros em todos os aviões seria aleatória, os dados indicavam na verdade quais aviões conseguiam voltar à base.

Aviões que levavam tiros na cabine do piloto ou no motor não sobreviviam, e por isso era nessas regiões que a blindagem extra deveria ser aplicada.



I de Moran: Definição, Fórmula e Lógica



Os valores perto de mim são parecidos comigo?

Conceito

- **Patrick Moran, 1950** — publicado em *Biometrika*, vol. 37, p. 17–23
- Desenvolvido independentemente por Moran na Austrália; formalizado depois por Cliff & Ord (1973)
- Escala: **-1 a +1** (análogo ao coeficiente de correlação de Pearson, mas no domínio espacial)

Valor de I	Interpretação	No Proagro
+0.7 a +1.0	Positiva forte	Evento regional bem delimitado (seca extensa, geada generalizada)
+0.4 a +0.7	Positiva moderada	Evento com gradientes (transição entre região afetada e não afetada)
+0.1 a +0.4	Positiva fraca	Componente regional fraco, fatores locais dominam
-0.1 a +0.1	Independência espacial	Fenômenos localizados ou idiossincráticos
< -0.1	Negativa (tipo xadrez)	Muito raro em dados agroclimáticos

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

Lógica intuitiva em 3 passos

1. Para cada município, calcular o desvio da média: $\bar{x}$
2. Para cada par de vizinhos, multiplicar desvios: se ambos acima da média $\rightarrow$ produto positivo; se um acima e outro abaixo $\rightarrow$ produto negativo
3. Somar, ponderar pela vizinhança W_{ij} , normalizar pela variância total

Matrizes de Vizinhaça: A Decisão Mais Importante



Quem É Vizinho de Quem? A Matriz de Pesos Espaciais

Critério	Como funciona	Quando usar
Contiguidade Rainha	Vizinhos = compartilham fronteira ou vértice	Análise por municípios, microrregiões
Contiguidade Torre	Vizinhos = compartilham apenas fronteira (não vértice)	Raro na prática; mais conservador
K vizinhos mais próximos	Cada unidade tem exatamente k vizinhos (os mais próximos)	Análise por glebas ou pontos ($k=5$ a 8)
Distância fixa	Vizinhos = centróides a menos de d km	Quando o raio de influência é conhecido

*A matriz de pesos espaciais é **uma decisão do analista**, não um dado natural. Sempre reportar qual critério foi utilizado e, preferencialmente, testar com mais de uma definição de vizinhança. Se o resultado se mantém, é robusto.*

Significância Estatística: Permutação de Monte Carlo



*Um I de 0.35 parece bom — mas seria
esperado por acaso?*

- O I de Moran calculado é **um número** — mas precisamos saber se esse número é maior do que o esperado sob hipótese nula de aleatoriedade
- Hipótese nula: os valores estão distribuídos aleatoriamente no espaço (qualquer permutação é igualmente provável)
- **Não podemos usar testes paramétricos** (como o t de Student) diretamente, porque a distribuição do I depende da geometria da vizinhança

Como funciona a permutação de Monte Carlo

(Hope, 1968; Cliff & Ord, 1981)

1. Calcular o I de Moran observado com os dados reais
2. Embaralhar aleatoriamente os valores entre as localizações (manter o mapa, trocar os números de lugar)
3. Recalcular o I para essa permutação
4. Repetir passos 2–3 muitas vezes (padrão: 999 permutações)
5. Comparar o I real com a distribuição das 999 permutações
6. Pseudo p-valor = $(R + 1) / (M + 1)$, onde R = nº de permutações com $I \geq I$ observado, M = nº total de permutações

Pseudo p-valor	Interpretação	Com 999 permutações
$p < 0.001$	Evidência fortíssima — padrão robusto	I real maior que todos os 999 embaralhados
$p < 0.01$	Evidência forte — padrão consistente	I real no top 1% da distribuição
$p < 0.05$	Significativo — padrão aceitável	I real no top 5%
$p > 0.05$	Não significativo — pode ser acaso	I real não se destaca da distribuição



$I = 0.52$ com $p = 0.14 \rightarrow$ **NÃO** podemos afirmar autocorrelação



$I = 0.18$ com $p = 0.003 \rightarrow$ autocorrelação fraca mas **REAL** e significativa


A magnitude do I e a significância são informações complementares, nunca substitutivas.

Diagrama de Moran: Visualizando a Classificação Espacial



Diagrama de Moran: Visualizando a Classificação Espacial

Quadrante	Sigla	Significado	No Proagro
Superior direito	HH (Alto-Alto)	Valor alto, vizinhos altos	Hotspot: cluster de alta sinistralidade
Inferior esquerdo	LL (Baixo-Baixo)	Valor baixo, vizinhos baixos	Coldspot: cluster de baixa sinistralidade
Inferior direito	HL (Alto-Baixo)	Valor alto, vizinhos baixos	Outlier: município destoia — por quê?
Superior esquerdo	LH (Baixo-Alto)	Valor baixo, vizinhos altos	Outlier: município "escapou" do padrão



"O Diagrama de Moran classifica cada unidade. Mas não diz quais classificações são estatisticamente significativas. Para isso, precisamos da LISA."

LISA: Do Global ao Mapa de Clusters



Cada município recebe sua própria classificação, com teste de significância

A referência fundadora:

Anselin, L. (1995). "Local Indicators of Spatial Association — LISA." *Geographical Analysis*, 27(2), 93–115. — Um dos artigos mais citados em toda a análise quantitativa de dados geográficos.

Conceito central:

- LISA **decompõe** o I global em contribuições individuais de cada localização
- Propriedade fundamental: a soma dos I locais é proporcional ao I global
- Cada município recebe:
 - Seu **I local** (positivo ou negativo)
 - Seu **pseudo p-valor** (via permutação condicional)
 - Sua **classificação** (se significativo)

Categoria	Cor no mapa	Significado	Relevância no Proagro
HH	Vermelho	Alto cercado de altos	Hotspot: cluster de alta sinistralidade confirmado
LL	Azul escuro	Baixo cercado de baixos	Coldspot: cluster de baixa sinistralidade confirmado
HL	Rosa/Laranja	Alto cercado de baixos	Outlier espacial: município destoia dos vizinhos
LH	Azul claro	Baixo cercado de altos	Outlier espacial: município "escapou" do padrão regional
NS	Cinza	Não significativo	Sem padrão local detectável

*LISA é onde a análise espacial se torna **acionável**: não apenas 'há padrão', mas **quais unidades** formam o padrão e com que confiança.*

LISA: Aplicações



Sinistros Declarados × Condição Climática

A análise mais poderosa para avaliar coerência espacial

Fluxo analítico em 3 passos:

1. Gerar mapa LISA da **taxa de COPs por seca** (agregado por município)
2. Gerar mapa LISA do **déficit hídrico acumulado** (a partir de dados pluviométricos interpolados)
3. **Sobrepor e comparar** as classificações

Cenário	LISA das COPs	LISA do Clima	Interpretação
Coerente	HH (hotspot COPs)	HH (hotspot déficit)	Perdas refletem evento climático real — padrão esperado
Anomalia potencial	HH (hotspot COPs)	LL ou NS (sem déficit)	Muitas perdas declaradas onde clima foi normal — merece investigação
Subnotificação?	LL ou NS	HH (hotspot déficit)	Clima adverso severo, mas poucas comunicações de perda
Outlier misto	HL (outlier COPs)	NS	Município isolado com muitas COPs, sem padrão regional climático nem de sinistro

*Esta sobreposição é, no plano conceitual, uma das aplicações mais valiosas da estatística espacial para o Proagro. No estudo de Woodard et al. (2012) publicado no *Journal of Risk and Insurance*, a análise da coerência espacial entre sinistros e condições climáticas nos EUA revelou transferências sistemáticas de prêmios da ordem de 26% do total — evidência de desajuste espacial no programa americano de seguro agrícola.*

Contar COPs por gleba ou produtor ao longo de múltiplas safras

Frequência	Classificação	Interpretação
1 COP	Eventual	Evento isolado — esperado em qualquer sistema
2–3 COPs	Recorrente	Vulnerabilidade ou risco elevado
4+ COPs	Crônico	Padrão persistente — merece contexto

É possível mapear espacialmente a taxa de recorrência e aplicar LISA sobre essa variável

Cenários interpretativos:

- Recorrência concentrada em região com alta vulnerabilidade climática conhecida (ex.: semiárido, solos rasos) → **coerente com risco estrutural**
- Recorrência concentrada sem suporte climático → **sinal para aprofundamento**
- Recorrência dispersa aleatoriamente → **padrão idiossincrático (espalhada e aleatória), sem dimensão espacial**

 *Recorrência **não** é sinônimo de irregularidade. Há regiões genuinamente vulneráveis onde perdas repetidas são a realidade agroclimática. O papel da análise espacial é **contextualizar**, nunca rotular.*

Lógica:

- Estratificar COPs por agente: Instituição Financeira, perito, cooperativa
- Para cada subconjunto, calcular densidade ou taxa no espaço
- Comparar o padrão espacial do subconjunto com o padrão geral da região
- Aplicar LISA comparativo quando o volume de dados permitir

Exemplo conceitual:

“Se a IF “A” opera em 50 municípios e sua taxa de COPs é uniformemente mais alta que a média regional, isso pode refletir uma carteira concentrada em regiões vulneráveis.

Mas se a taxa da IF “A” é alta apenas em 5 municípios específicos, enquanto nos outros 45 é normal — temos concentração atípica que merece contexto.

 *“Desvio espacial por agente não implica fraude. Pode refletir especialização geográfica, composição de carteira, critérios de perícia, ou simplesmente que aquele agente atende uma região mais vulnerável. São sinais para investigação contextualizada, nunca conclusões definitivas.*

MAUP e a Falácia Ecológica: Armadilhas da Escala



¡Por que os mesmos dados podem contar histórias diferentes em escalas diferentes!

MAUP — Modifiable Areal Unit Problem (Openshaw, 1984)

- - Os resultados estatísticos mudam quando alteramos a unidade de agregação
- - Dois efeitos:
 - **Efeito de escala:** análise por município vs. por microrregião vs. por estado → resultados diferentes
 - **Efeito de zonal:** mesma escala, fronteiras diferentes → resultados diferentes

Exemplo: I de Moran para COPs pode ser 0.45 por município e 0.71 por microrregião — qual está "certo"? Ambos, mas medem coisas diferentes

Falácia ecológica (Robinson, 1950):

- Padrões observados em dados agregados (municípios) **não podem** ser diretamente atribuídos a indivíduos (produtores)
- "O município X é hotspot de COPs" $\neq$ "todos os produtores do município X têm comportamento atípico"

"Para o Proagro: análise por município é útil para visão regional; análise por gleba é útil para foco local. Reportar sempre a escala utilizada e evitar afirmações sobre indivíduos a partir de dados agregados."

Limitações e Boas Práticas



- **Múltiplos testes:** Com 400 municípios testados a 5%, ~20 serão "significativos" por acaso. Soluções:
 - Correção de **Bonferroni** (conservadora: divide α pelo nº de testes)
 - Correção de **FDR** (Benjamini & Hochberg, 1995) — mais adequada para LISA (Caldas de Castro & Singer, 2006)
- **I global baixo $\neq$ sem padrões locais** Hotspot + coldspot em lados opostos do mapa podem se cancelar na média global
- **Não é causalidade:** Autocorrelação espacial indica associação geográfica, **não** relação causa-efeito
- **Sensibilidade à vizinhança:** Sempre testar com pelo menos duas definições de vizinhança
- **Qualidade dos dados:** Resultados são tão bons quanto os dados de entrada (Sicor confiável a partir de 2013)

Checklist de qualidade para qualquer análise LISA:

1. Reportar: critério de vizinhança utilizado
2. Reportar: nº de permutações
3. Reportar: método de correção para múltiplos testes
4. Testar robustez com pelo menos uma definição alternativa de vizinhança
5. Contextualizar com dados climáticos, agroeconômicos e temporais
6. Documentar escala de análise e limitações

Obrigado!

meteorologiageotec.derop@bcb.gov.br



LinkedIn

DÚVIDAS?



bcb.gov.br

