

A satellite with two large solar panels is in orbit over a green, patchwork landscape. The background is a green gradient with a pattern of small white dots.

Análise Espacial, Estatística e Técnicas de Interpolação

Aula 3 - Módulo 2

Me. Gabriel Luan Rodrigues
Março 2026

1. Fundamentos de Análise Espacial + Mapas de Densidade Kernel
2. Estatística Espacial: I de Moran, LISA e Detecção de Outliers e Anomalias
- 3. Técnicas de Interpolação Espacial: IDW, Spline e Krigagem**
4. Aulas Práticas

AVISO!

**A PARTIR DA SEMANA QUE VEM,
MENTORIAS ÀS SEXTAS-FEIRAS DE MANHÃ
DAS 9H ÀS 12H**

Próxima Mentoria: 20/03 (sexta)

O Problema Fundamental



Quanto choveu exatamente na gleba do produtor?"

O cenário real:

- Produtor comunica perda por seca numa gleba no RS
- Estação mais próxima: 47 km ao nordeste
- Segunda mais próxima: 68 km ao sul
- Terceira: 82 km a oeste
- **Nenhuma estação está na gleba**

Da rede de estações

- Cobertura irregular
- Média: distância média ~70 km e até > ~450km entre estações
- Estações automáticas: maioria instalada após 2010
- Concentração em centros urbanos; lacunas no Norte, Semiárido e fronteira agrícola do MT

Então: Como estimar precipitação *naquela gleba específica*?

Uma possibilidade: Técnicas de interpolação espacial — estimar valores em locais sem medição direta, usando dados de pontos medidos próximos



Por que importa para interpolação:

- Se coisas próximas NÃO fossem mais parecidas, interpolar seria impossível
- Como Goodchild observou: sem essa lei, "toda a gama de condições da superfície terrestre poderia estar empacotada dentro de qualquer área pequena"
- A questão operacional não é SE coisas próximas se parecem, mas COMO essa similaridade decai com a distância

Quando isso falha:

- Granizo (escala 1–10 km, duração 1–12 h)
- Inversões térmicas, tornados
- Fronteiras de uso do solo

Fenômenos que violam autocorrelação → interpolação não funciona bem

Método	Como traduz a Lei de Tobler
IDW	Peso = $1/d^p$ — diretamente proporcional à proximidade
Spline	Restrição de suavidade — transições graduais entre vizinhos
Krigagem	Semivariograma — mede empiricamente como a similaridade decai com a distância

Comparação entre os métodos

Aspecto	IDW	Spline	Krigagem
Filosofia	Média ponderada pela distância inversa	Superfície suave que minimiza curvatura	Pesos ótimos baseados na estrutura espacial dos dados
Formulação original	Shepard (1968)	Wahba (1990); Hutchinson (1995)	Krige (1951); Matheron (1963)
Pesos baseados em	Distância geométrica pura	Minimização de funcional de curvatura	Semivariograma empírico
Pressupostos	Nenhum sobre distribuição	Suavidade da superfície	Estacionariedade (ao menos intrínseca)
Parâmetros	p (potência), k (vizinhos)	λ (suavização), tensão	Modelo de variograma (nugget, sill, range)
Quantifica incerteza?	✗ Não	✗ Não	✓ Sim (variância de krigagem)
Complexidade	Baixa	Média	Alta
Efeito visual	"Bull's eye" (círculos concêntricos)	Superfícies lisas e graduais	Suave + mapa de incerteza
Quando preferir	Análise rápida; rede densa de pontos	Variáveis suaves (temperatura); superfícies climáticas	Decisões que exigem confiabilidade; rede esparsa

IDW (Inverse Distance Weighting)



O método mais intuitivo

Onde:

- $\hat{z}(x_0)$ = valor estimado no ponto desconhecido
- z_i = valor observado na estação *i*
- d_i = distância do ponto x_0 à estação *i*
- p = expoente de ponderação (power parameter)
- n = número de estações vizinhas consideradas

Propriedade fundamental: Interpolador exato — se x_0 coincide com uma estação, retorna o valor observado

$$\hat{z}(x_0) = \frac{\sum_{i=1}^n \frac{z_i}{d_i^p}}{\sum_{i=1}^n \frac{1}{d_i^p}}$$

Estação	Distância à gleba	Precipitação	Peso (p=2)	Peso normalizado
A	25 km	180 mm	$1/625 = 0,00160$	0,616
B	40 km	210 mm	$1/1600 = 0,000625$	0,240
C	75 km	145 mm	$1/5625 = 0,000178$	0,068
D	90 km	195 mm	$1/8100 = 0,000123$	0,047
E	110 km	160 mm	$1/12100 = 0,0000826$	0,028
Soma			$\Sigma = 0,0026086$	$0,999 \approx 1$

Cálculo:

$$\hat{Z} = 0,616 \times 180 + 0,241 \times 210 + 0,069 \times 145 + 0,047 \times 195 + 0,027 \times 160$$

$\hat{Z} \approx 188 \text{ mm}$ (dominada pela Estação A, que tem 61,6% do peso)

Interpretação hipotética:

- Normal climatológica jan no município: $\sim 150 \text{ mm}$
- Se COP alega seca severa e interpolação estima 188 mm $\rightarrow$ **inconsistência a investigar**

O parâmetro “p”, o efeito bull's-eye e o problema do agrupamento

O parâmetro **p** — o controle fundamental:

Valores típicos

- Para precipitação: **p ótimo tipicamente entre 1,5 e 4****
- Para temperatura: **p ótimo entre 2 e 3**
- **Determinar p por validação cruzada** (leave-one-out), minimizando RMSE

Valor de p	Comportamento	Analogia
$p \rightarrow 0$	Todos os pesos iguais $\rightarrow$ média aritmética simples	Desconsidera totalmente a proximidade
$p = 1$	Influência decai linearmente com a distância	Estações distantes ainda têm peso significativo
$p = 2$	Padrão (Shepard, 1968) — decaimento quadrático, análogo à gravidade	Equilíbrio razoável entre influência local e global
$p = 3$ a 5	Forte domínio do vizinho mais próximo	A superfície se aproxima dos polígonos de Thiessen
$p \rightarrow \infty$	Convergência total para o vizinho mais próximo	Polígonos de Voronoi (Nearest Neighbor)

Limitação 1 — "Bull's eye" (olho de boi):

- Curvas concêntricas artificiais ao redor de cada estação
- Artefato visual sem significado físico
- Mais pronunciado com p alto e em áreas de relevo complexo
- - Franke & Nielson (1980) propuseram a "Modified Shepard's Method" com polinômios locais para mitigar

Limitação 2 — Viés por agrupamento de estações:

- Estações concentradas numa região recebem peso combinado desproporcional
 - Exemplo: 5 estações no entorno de Porto Alegre e 1 estação isolada no pampa → interpolação puxada para os valores de Porto Alegre
- Lu & Wong (2008) propuseram o AIDW (Adaptive IDW), com p variável no espaço, que superou krigagem ordinária em certos cenários

Limitação 3 — Sem medida de incerteza:

- IDW entrega um número, sem intervalo de confiança
- Não há como saber se 188 mm significa "tenho confiança" ou "é um chute"

Parâmetro adicional: número de vizinhos (k)

- Estudos reportam k ótimo entre **5 e 15 para dados meteorológicos**
- Preferir raio variável (k vizinhos mais próximos) ao invés de raio fixo, especialmente com rede irregular

Spline: Superfícies Suaves



Pregos (estações) em alturas diferentes (valores). Spline = folha elástica que toca todos os pregos, curvando-se o mínimo possível entre eles.

Formulação (Thin-Plate Smoothing Spline):

- Minimiza: $\sum_i (z_i - f(x_i))^2 / w_i + \lambda \cdot J(f)$
- Onde $J(f)$ é a penalidade de curvatura (integral de derivadas parciais)
- $\lambda \rightarrow 0$: interpolação exata (toca todos os pontos)
- $\lambda \rightarrow \infty$: superfície tende a polinômio de tendência (suavização máxima)
- - λ escolhido por **GCV (Generalized Cross-Validation)**

Incorporar altitude como covariável faz "contribuição dominante" traz melhoras significativas para a temperatura

Tipos:

- **Regularized Spline:** tensão ajustável entre "placa de aço" (oscilante) e "membrana" (rígida)
- **Thin-Plate Spline:** minimiza curvatura total — o mais usado em climatologia

Ponto	IDW ($p=2$)	Spline
Gleba entre Est. 2 (195 mm) e Est. 3 (150 mm), mais perto da 2	~180 mm	~175 mm (transição mais suave, captura tendência de decréscimo)

Vantagens:

- Mapas visuais naturais, sem "bull's-eye"
- Bom para variáveis com variação suave (temperatura, precipitação mensal/anual)
- Não requer modelagem subjetiva de variograma
- Equivalência matemática com krigagem $\sim$ spline $\equiv$ krigagem com covariância fixa

Limitações:

- Sem incerteza
- **Overshoot/undershoot:** pode gerar precipitação negativa ou picos irreais nas bordas
- Assume suavidade que nem sempre existe (chuva convectiva intensa não é suave)

Krigagem




Antes de interpolar, a Krigagem estuda os dados...


- Daniel Krige (1951): engenheiro de minas, Witwatersrand (África do Sul) — usou regressão estatística para estimar teor de ouro em sondagens
- Georges Matheron (1963): formalizou tudo em "Principles of geostatistics" (*Economic Geology*) — criou o conceito de **variável regionalizada** e o termo "krigeage"
- Matheron (1962–63, *Traité de géostatistique appliquée*; 1971, *Théorie des variables régionalisées*)

$$\gamma(h) = \frac{1}{2N(h)} \sum_{i=1}^{N(h)} [z(x_i) - z(x_i + h)]^2$$

Onde:

- $\gamma(h)$ = semivariância na distância h
- $N(h)$ = número de pares de pontos separados por h
- $z(x_i)$ = valor observado no ponto x_i






Razão Nugget/Sill — Classificação de Cambardella et al. (1994):

- $< 0,25 \rightarrow$ **Forte** dependência espacial
- $0,25$ a $0,75 \rightarrow$ **Moderada**
- $> 0,75 \rightarrow$ **Fraca** (quase nugget puro)

Valores típicos para variáveis meteorológicas:

- Precipitação (mensal): nugget alto, range **50–300 km**
- Temperatura: nugget baixo, range **100–500 km*** (mais contínua espacialmente)

Se o range é 70 km e a estação mais próxima está a 120 km, aquela estação praticamente não contribui para a estimativa. A interpolação ali será de baixa qualidade — e a Krigagem vai avisar disso, via variância alta.



Componente	O que é	Interpretação prática
Nugget (C_0)	Semivariância em $h \rightarrow 0$	Erro de medição + variação microescala (abaixo do espaçamento entre estações)
Sill ($C_0 + C_1$)	Patamar — variância total	Variabilidade total na região
Range (a)	Distância onde γ atinge o patamar	Além desta distância, estações não contribuem para a interpolação

*Ajuste de modelo, cálculo de pesos ótimos e o mapa que diz
"não confie em mim aqui"*

Passo 1: Ajustar um modelo teórico ao semivariograma empírico

- Modelo **exponencial** é o mais frequente na literatura para precipitação

Passo 2: Calcular pesos ótimos — a "mágica" da Krigagem

- Pesos λ_i que minimizam a variância do erro de predição
- Restrição: $\sum \lambda_i = 1$ (não-enviesado)
- Diferente do IDW: pesos **NÃO** dependem apenas da distância ao ponto — dependem também da **distância entre estações** (evita redundância de estações agrupadas)

Passo 3: Estimar valor e variância

- Estimativa: $\hat{Z}(x_0) = \sum \lambda_i \cdot z(x_i)$
- Variância de Krigagem: $\sigma^2_{\square}(x_0)$ — depende **apenas da geometria e do variograma**, não dos valores

Modelo	Comportamento na origem	Range efetivo (95% do sill)	Quando usar
Esférico	Subida linear	a	Fenômenos com correlação finita clara
Exponencial	Subida íngreme	3a	Precipitação diária/mensal (mais usado na meteorologia)
Gaussiano	Subida parabólica (lenta)	$\sqrt{3} \cdot a$	Fenômenos muito contínuos e suaves

Limitação crítica da variância de Krigagem:

*"A variância de Krigagem **NÃO** depende dos valores observados — depende apenas da posição das estações e do modelo de variograma. Duas glebas na mesma posição terão a mesma variância, mesmo que os dados ao redor sejam concordantes ou extremamente discordantes."*

- É um indicador de **geometria amostral**, não de **erro real de predição**
- Para erro real: usar **validação cruzada**

Anisotropia e Covariáveis: Refinando a Krigagem



Anisotropia — a correlação muda conforme a direção:

- **Isotrópica:** o range é igual em todas as direções (semivariograma "circular")
- **Anisotrópica:** o range muda por direção (semivariograma "elíptico")
- **Causa meteorológica:** ventos predominantes, cadeias de montanhas, gradientes latitudinais
- Detectada via semivariogramas direcionais (0°, 45°, 90°, 135°) ou superfície 2D de variograma

Exemplo (conceitual):

Numa região de Serra, precipitação varia mais rápido na direção E–W (perpendicular à serra) do que N–S (paralela) → $Range(N-S) > Range(E-W)$ → anisotropia geométrica

Krigagem Universal (KED — Kriging with External Drift):

- Incorpora uma tendência determinística: $Z(x) = m(x) + \varepsilon(x)$
- Variáveis de tendência comuns: altitude (DEM), latitude, distância ao mar
- Ideal quando há correlação física entre a variável e a covariável

Co-Krigagem:

- Interpola a variável primária (precipitação) usando uma variável secundária (altitude) que tem mais observações

Quando vale a pena o esforço adicional:

- - Rede **esparsa** + relevo **complexo** + correlação com altitude → KED ou Co-Krigagem
- - Rede **densa** em planície → Krigagem Ordinária ou IDW já são adequados
- - Na escala **diária** altitude agrega pouco; na escala **mensal/anual** faz diferença

Qual Método Funciona Melhor?



Estudo 1 — Xavier et al. (2016, 2022):

- Dataset: BR-DWGD, 11.473 pluviômetros + 735 estações, 1961–2020
- Resolução: $0,1^\circ \times 0,1^\circ$
- Testaram 6 métodos: **IDW e ADW foram os melhores para precipitação**
- Conclusão: variação entre bacias explicada pela **densidade da rede**, não pelo método
- RMSE Tmax: $1,557^\circ\text{C}$ | RMSE Tmin: $1,616^\circ\text{C}$
- Acurácia pior antes de 1995 (menos estações) → qualidade temporal heterogênea

Estudo 2 — Borges et al. (2016):

- Distrito Federal, 60 estações, 1971–2000
- IDW, Krigagem Ordinária e Regressão Multivariada: erros similares e alta eficiência
- *"Interpolation methods provide similar spatial distributions wherever observation network is dense."*
- Em rede esparsa: inclusão de variáveis geográficas melhora estimativas

Estudo 3 — Carvalho, Assad & Vieira:

- São Paulo, 1.027 pluviômetros, 1957–1997
- IDW, Curvatura Mínima (Spline), Krigagem Ordinária
- Diferenças visuais pequenas, mas Krigagem com *vantagem no erro quadrático médio*

Estudo 4 — Embrapa-Pará (2017):

- **Amazônia:** apenas 4 estações automáticas para 49 municípios
- **Krigagem Ordinária: método mais adequado** para rede extremamente esparsa

Situação no Brasil	Recomendação
Rede densa	IDW — simples, robusto, comparável à Krigagem
Rede moderada	Krigagem Ordinária — incerteza como diferencial
Rede esparsa + relevo	KED / Co-Krigagem com altitude
Escala diária, qualquer rede	IDW ou Krigagem Ordinária (altitude agrega pouco)
Necessidade de incerteza formal	Krigagem (qualquer variante)

Incerteza



Incerteza na Interpolação: O Que Não Podemos Ignorar

O que aumenta a incerteza:

- - Poucas estações; distância grande à gleba; distribuição irregular; relevo complexo; dados com falhas; fenômenos altamente localizados

Validação cruzada — o teste de realidade:

- **Leave-One-Out CV (LOO-CV):** remove cada estação, estima com as demais, calcula erro
- Métricas padrão: RMSE, MAE, Viés (Bias)
- Para Krigagem: erro padronizado médio ≈ 0 e RMSE padronizado $\approx 1 \rightarrow$ variograma adequado
- Se RMSE padronizado $\gg 1 \rightarrow$ variograma subestima a incerteza
- Se RMSE padronizado $\ll 1 \rightarrow$ variograma superestima (modelo impreciso)

Cenário ideal: Comparação de fontes independentes e verificar a convergência

- Para cada COP, cruzar **no mínimo 3 fontes independentes**:
 1. Interpolação de estações (Krigagem/IDW dos dados INMET)
 2. Produto em grade (MERGE, CHIRPS, ERA5, NASA-POWER, etc)
 3. Índice de vegetação (NDVI médio no período crítico)

Matriz de decisão hipotética:


Glebas (COP seca)	Krigagem	MERGE	NDVI	Conclusão
G1	178 ± 12 mm	185 mm	0,68 (normal)	✗ Inconsistente com seca
G2	142 ± 18 mm	138 mm	0,42 (baixo)	✓ Consistente com seca
G3	165 ± 25 mm (alta inc.)	152 mm	0,51 (médio)	⚠ Inconclusivo — peso a MERGE/NDVI
G4	155 ± 10 mm	162 mm	0,60 (normal)	✗ Inconsistente (3 fontes concordantes)

"Nenhuma fonte isolada decide. Todas juntas constroem o quadro. Quando a incerteza é alta, a decisão correta é buscar mais evidências, não forçar uma conclusão."

Trilha de Integração para Interpolação no Proagro



Onde a Interpolação Se Encaixa no Workflow



O Risco de Base Espacial no Seguro Agrícola



¡A Distância da Estação Custa Dinheiro!

O que é risco de base espacial (Spatial Basis Risk)?

- Diferença entre o que o índice climático (medido na estação) indica e o que realmente aconteceu na gleba
- Produtores podem: (a) ter perda real sem receber indenização (falso negativo), ou (b) receber sem ter tido perda (falso positivo)
- Quanto maior a distância gleba–estação, maior o risco de base

Evidência empírica:

- Desempenho do seguro indexado degrada significativamente **além de 20–25 km** da estação
- "O número de estações na área de interpolação tem impacto maior no risco de base do que a escolha da técnica de interpolação"
- Para milho nos EUA, índices interpolados reduziram risco de base em **27–29%** versus vizinho mais próximo; Krigagem com regressão foi o mais eficaz

Implicação para o Proagro:

- A rede de estações no Brasil → muitas glebas além do limiar de 20–25 km
- ZARC usa ~3.500 séries pluviométricas (INMET + HidroWeb + CPTEC) — mais densa, mas temporal
- **Produtos em grade (MERGE, CHIRPS) reduzem o risco de base** por oferecer cobertura espacial contínua
- A combinação estação + grade + satélite é o caminho para minimizar o risco de base

A qualidade da interpolação tem impacto financeiro direto: cada “km” a mais de distância entre a gleba e a estação mais próxima aumenta a probabilidade de erro na decisão de indenização."

Usar com confiança:

- ✓ Análise regional de tendências climáticas (mensal, sazonal, anual)
- ✓ Criação de mapas contextuais de risco para priorização
- ✓ Ranqueamento de COPs por divergência clima x perda declarada
- ✓ Complemento a produtos de grade em regiões com boa cobertura de estações
- ✓ Estimativa de variáveis suaves: temperatura média, precipitação mensal acumulada

Evitar ou usar com extrema cautela:

- ✗ Decisão individual de alto impacto baseada **apenas** em interpolação
- ✗ Áreas com < 10 estações num raio compatível com o range do variograma
- ✗ Fenômenos extremamente localizados (granizo, tornados, alagamentos pontuais)
- ✗ Relevo complexo sem covariáveis (altitude, distância ao mar)
- ✗ Dados de entrada não validados (controle de qualidade não realizado)
- ✗ Precipitação diária em áreas de convecção intensa (variabilidade extrema em curta distância)

Checklist pré-interpolação:

Verificação	Status necessário
Controle de qualidade dos dados	✓ Outliers removidos, falhas tratadas
Estações suficientes (>10 no domínio)	✓ Verificado
Semivariograma mostra estrutura (não é nugget puro)	✓ Confirmado
Fenômeno é espacialmente contínuo	✓ Não é granizo/tornado
Resultado será cruzado com outras fontes	✓ MERGE + NDVI disponíveis

Interpolação é estimativa, não medição. É ferramenta de apoio à decisão qualificada, não substituto. Use-a com rigor, transparência e consciência de suas limitações!

Encerramento do Módulo 2



- **Aula 1:** A dimensão espacial importa — KDE revela padrões visuais, concentrações e vazios
- **Aula 2:** I de Moran confirma estatisticamente; LISA mapeia hotspots, pontos frios e outliers espaciais
- **Aula 3:** Interpolação preenche lacunas entre estações, com três métodos de complexidade crescente e quantificação de incerteza (Krigagem)

Na prática...

Conceito

Fenômeno

Dado

Indicador

Decisão

AVISO!

**A PARTIR DA SEMANA QUE VEM,
MENTORIAS ÀS SEXTAS-FEIRAS DE MANHÃ
DAS 9H ÀS 12H**

Próxima Mentoria: 20/03 (sexta)

Obrigado!

meteorologiageotec.derop@bcb.gov.br



LinkedIn

DÚVIDAS?



bcb.gov.br

