

Modelagem de Perdas Agrícolas e Aplicações em Decisão

Aula 1 - Módulo 4

Me. Gabriel Luan Rodrigues
Abril 2026

Como são construídos os modelos de perdas



Objetivo	Descrição
Estimar magnitude da perda	Quantificar quanto se perdeu (ou se espera perder) em kg/ha
Apoiar decisões de seguro	Calibrar gatilhos de indenização, precificar prêmios, validar laudos
Atribuir perdas a eventos	Separar efeito de seca, geada, granizo, chuva excessiva
Zoneamento de risco climático	Base do ZARC — quais culturas, onde e quando plantar
Detectar anomalias	Discrepâncias entre perda esperada pelo clima e perda alegada

Perdas agrícolas recentes no Brasil

Evento	Período	Região	Impacto
Seca severa (La Niña)	2021/2022	Sul e Centro-Oeste	Indenizações do Proagro quadruplicaram em relação à safra anterior
Enchentes históricas	Maio/2024	Rio Grande do Sul	Devastação em arroz (~70% da produção nacional), soja, leite
Seca histórica no Cerrado	2024	Centro-Oeste e MATOPIBA	Impacto em soja, milho safrinha e algodão
Geadas severas	Julho/2021	PR, SC	Danos a café, trigo e fruticultura
Granizo recorrente	Safras diversas	RS, SC, PR	Trigo, tabaco, fruticultura
Chuva excessiva na colheita	Safras diversas	Sul e Sudeste	Perda de qualidade de grãos (soja, trigo)

ZARC

Já é, em essência, um modelo de perdas

Usa balanço hídrico + soma térmica + dados de solo para definir janelas de plantio com risco $\leq 20\%$, 30% ou 40% .

SICOR

Registra a operação e a alegação

Operações de crédito rural, COPs (Comunicações de Ocorrência de Perdas) e laudos periciais.

Modelo de perdas

Faz a ponte entre os dois

Confronta perda esperada pelo clima com perda declarada — gera indicador proxy de plausibilidade.

A confrontação entre modelo e COP **não é prova** — é um indicador proxy para **priorizar investigação**.

Modelos são instrumentos de priorização, nunca de acusação.

Como são construídos os modelos de perdas



Eixo 1 — Produtividade

- **IBGE/PAM** — produtividade municipal (kg/ha) desde os anos 1970
- **CONAB** — estimativas oficiais de safra
- **NDVI/EVI** — proxy de vigor vegetativo via satélite

Eixo 2 — Meteorologia

- **INMET** — estações convencionais e automáticas
- **MERGE / CHIRPS** — precipitação em grade
- **ERA5-Land, NASA POWER** — reanálise atmosférica
- **SAMET** — temperatura em grade no Brasil

Como o clima afeta a produtividade

Fase fenológica	Variável crítica	Efeito da adversidade
Germinação / Emergência	Umidade do solo	Falha de estande, replantio
Vegetativo	Precipitação, temperatura	Redução de área foliar, crescimento lento
Floração / Polinização	Temperatura extrema ($> 35^{\circ}\text{C}$)	Abortamento floral, redução da viabilidade do pólen
Enchimento de grãos	Déficit hídrico	Grãos leves, redução direta de massa
Maturação / Colheita	Chuva excessiva	Perda de qualidade, germinação na espiga

depende do estágio fenológico

Tipos de Modelos de Simulação/ Predição de Rendimento

FAMÍLIA 1

Empíricos / Estatísticos

Regressão, séries temporais, NDVI. Simples e transparentes.

FAMÍLIA 2

Agroclimáticos

Índices (SPI, SPEI, GDD), balanço hídrico de Thornthwaite-Mather.

FAMÍLIA 3

Mecanísticos

DSSAT, APSIM, AquaCrop — simulação fisiológica do cultivo.

FAMÍLIA 4

Aprendizado de Máquina

Random Forest, XGBoost, redes neurais (CNN-LSTM).

Eixo de complexidade → da regressão linear ao deep learning.

Eixo de interpretabilidade ↓ quanto mais complexo, mais difícil de explicar.

Empíricos



$$Y_{\text{município}} = \alpha + \beta_1 \cdot P_{\text{safr}} + \beta_2 \cdot T_{\text{média}} + \beta_3 \cdot P^2 + \gamma \cdot \text{tendência} + \varepsilon$$

Vantagens: simples, transparente, baixo custo computacional

Limitações: assume relação linear ou polinomial; não captura interações nem dinâmica fenológica

Uso no Proagro: linha de base para comparar com abordagens sofisticadas; fácil de comunicar

SÉRIES TEMPORAIS

- ARIMA, decomposição
aditiva/multiplicativa, médias móveis
- Separa **tendência tecnológica** do sinal
climático
- Resíduos negativos em anos adversos =
perda estimada

NDVI COMO PROXY

- Pico de NDVI no enchimento
correlaciona-se com a produtividade final
- NDVI integrado $\approx$ proxy de produção
acumulada
- Combinar **NDVI + clima** melhora
significativamente a predição

Agroclimáticos



- **SPI** (McKee et al., 1993) — só precipitação; multiescalar (1, 3, 6, 12 meses)
- **SPEI** (Vicente-Serrano et al., 2010) — incorpora $P - E_{To}$; sensível à aridificação por T alta
- Padronizados → **comparáveis** entre regiões e épocas

Valor	Classificação
$\geq 2,0$	Extremamente úmido
1,5 a 1,99	Muito úmido
1,0 a 1,49	Moderadamente úmido
-0,99 a 0,99	Normal
-1,0 a -1,49	Moderadamente seco
-1,5 a -1,99	Severamente seco
$\leq -2,0$	Extremamente seco

GRAUS-DIA (GDD)

$$\text{GDD} = \sum (T_{\text{média}} - T_{\text{base}})$$

- Acumulação diária de T acima de uma base (soja: ~10 °C)
- Determina a velocidade do desenvolvimento fenológico
- Base do ZARC para ciclo por cultivar e região

BALANÇO HÍDRICO (THORNTHWAITE-MATHER, 1955)

Entradas: **T, P, latitude, CAD** do solo

Cadeia: $P \rightarrow ETo \rightarrow (P - ETo) \rightarrow ARM \rightarrow ETa, DEF, EXC$

Alimenta o modelo FAO-33 do ZARC

$$\text{Perda relativa} \\ Ky \cdot (1 - ETa / ETc)$$

Ky = sensibilidade ao déficit hídrico, varia por cultura e fase

Simulação de Cultivo




- Fotossíntese e acúmulo de biomassa
- Desenvolvimento fenológico (via GDD)
- Balanço hídrico no solo
- Absorção de nitrogênio
- Partição de fotoassimilados (folha, caule, raiz, grão)
- Estresse hídrico e térmico → penaliza cada componente


Aplicação didática: a produtividade simulada é um **benchmark** para comparar com a perda alegada.

*“O modelo simulou para a safra 2021/2022 uma produtividade de 1.800 kg/ha. O segurado declarou perda total. **A discrepância merece investigação** — não acusação.”*

- Desenvolvido desde os anos 1980;
- Estrutura modular: **Solo, Clima, Planta, Manejo**
- **CROPGRO** para leguminosas (soja); **CERES** para cereais (milho, trigo)
- Simula mais de 45 culturas
- Entradas: clima diário, perfil de solo, coeficientes genéticos, manejo
- Referência: Jones et al. (2003), *Eur. J. Agronomy*

Limitação-chave: exige **calibração dos coeficientes genéticos** de cada cultivar —
demanda dados experimentais.





APSIM · CSIRO / Austrália

Sistema de produção

Forte em **rotação de culturas** e ciclagem de nutrientes

Módulos para **pastagens tropicais** (Brachiaria) — relevante para o Brasil

Holzworth et al. (2014), *Env. Modell. Softw.*

AquaCrop · FAO

Simplicidade com fundamento

Trabalha com **cobertura de dossel (CC)** em vez de LAI

Fluxo: CC → Transpiração → Biomassa → Y (via HI)

4 modificadores de estresse hídrico

Steduto et al. (2009); FAO Water Report 47 (2021)

Modelos de Aprendizizado de Máquina



Algoritmos mais utilizados para soja e milho

Algoritmo	Tipo	Característica
Random Forest (RF)	Ensemble de árvores	Robusto, mede importância de variáveis
XGBoost / Gradient Boosting	Ensemble de árvores (boosting)	Geralmente o melhor para dados tabulares
SVM / SVR	Vetores de suporte	Bom para amostras pequenas
Redes Neurais (MLP)	Perceptron multicamadas	Flexível, exige mais dados
CNN (1D)	Convolucionais	Padrões em séries temporais de clima/NDVI
LSTM / BiLSTM	Recorrentes	Captura dependências temporais ao longo da safra
CNN-LSTM	Híbrido	Estado da arte para séries espaço-temporais

Resultados recentes no Brasil: ensemble ML alcançou **rRMSE ~6%** nacional e **~16%** municipal para soja (Monteiro et al., 2023/24).

VANTAGENS

- Alta acurácia preditiva com grandes volumes de dados
- Captura relações **não-lineares** e interações complexas
- Integra dados heterogêneos (clima, solo, NDVI, altitude)
- Treinamento rápido após preparação dos dados

LIMITAÇÕES

- Baixa interpretabilidade — “caixa-preta”
- Sensível à **qualidade e representatividade** dos dados de treino
- Desempenho fraco para **extremos fora da amostra**
- Aprende correlações, não mecanismos fisiológicos
- Risco de overfitting se a validação for mal desenhada

Quadro comparativo entre as famílias de modelos

Dimensão	Empírico	Agroclimático	Mecanístico	Aprendizado de Máquina
Base teórica	Associação estatística	Fisiologia simplificada	Fisiologia de processos	Orientado a dados
Dados mínimos	Y + 1–3 variáveis	T, P, CAD, latitude	Clima diário, solo, cultivar, manejo	Clima, NDVI, solo, Y
Custo	Muito baixo	Baixo	Moderado a alto	Baixo a alto (DL)
Interpretabilidade	Alta	Alta	Alta (processos)	Baixa a média
Captura extremos	Fraca	Moderada	Moderada	Fraca s/ treino c/ extremos
Resolução espacial	Municipal / estadual	Ponto ou grade	Ponto (extensível)	Pixel a município
Aplicação Proagro	Linha de base	ZARC, plausibilidade	Benchmark de produtividade	Triagem em larga escala

Limitações Espaciais e Temporais



A importância da escala espacial

PAÍS

Variância mínima

Padrões
macroclimáticos
emergem; sinal local
some.

ESTADO

Variância baixa

Útil para
macro-priorização;
pouca resolução fina.

MUNICÍPIO

Variância intermediária

Onde a maioria dos
modelos opera. Sinal
climático visível.

GLEBA

Variância máxima

Manejo, microrelevo,
solo — onde o sinistro
acontece.

A COP é **individual** (gleba); o modelo opera em **escala municipal ou de grade**. Esse descolamento é o **risco de base**.

ESPACIAL

Distância

A estação ou pixel está longe da gleba — gradientes locais não são captados.

TEMPORAL

Janela errada

O período do índice não coincide com a fase crítica da cultura.

DESIGN

Proxy inadequado

O índice escolhido não é bom proxy para a cultura ou peril (ex.: SPI em problema térmico).

Falso negativo: a gleba teve perda real, mas o índice não captou → produtor legítimo prejudicado.

Falso positivo: o índice indica condição adversa, mas a gleba não teve perda → potencial pagamento indevido.

01

Séries curtas

SPI/SPEI requerem ≥ 30 anos homogêneos. Muitas automáticas têm menos de 20 anos de registro.

02

Não-estacionariedade

Modelos calibrados em 1980–2010 podem subestimar perdas em 2020–2050: a distribuição conjunta de T e P está mudando.

03

Deriva tecnológica

A produtividade tendencial muda com genética e manejo, alterando a relação sinal/ruído.

04

Resolução temporal

Modelos mensais perdem eventos curtos: veranicos de 10 dias, geadas pontuais, granizo.

Extrapolação regional: modelo treinado no Paraná não serve automaticamente para MATOPIBA — culturas, solos e regimes de chuva são diferentes

Extrapolação temporal: anos extremos (enchente RS 2024, seca Cerrado 2024) podem estar fora da amostra de treino

Confundir índice com perda: $SPI = -2$ não significa necessariamente perda de 80% — a relação é estatística, específica por cultura, sujeita a variabilidade local

Regra de ouro: nenhum modelo ou índice deve ser usado como critério único e automático para aceitar ou rejeitar uma COP.

IDW — média ponderada por distância; simples, ignora estrutura espacial

Krigagem ordinária — usa o variograma para modelar autocorrelação; produz BLUE + mapa de incerteza

Krigagem por regressão — incorpora covariáveis (altitude, distância do mar)

Random Forest espacial — combina ML com coordenadas

Bucheli, Dalhaus & Finger (2021): krigagem reduziu o risco de base de seguros por calor em **27–29%** comparado com a estação mais próxima.

Obrigado!

meteorologiageotec.derop@bcb.gov.br



LinkedIn



bcb.gov.br



Detalhando os modelos



DETALHAMENTO — EMPÍRICOS

Regressão linear e múltipla

ETAPAS

1. Séries históricas pareadas (IBGE × MERGE)
2. Remover tendência tecnológica (detrending)
3. Ajustar regressão com variáveis climáticas por safra ou fase fenológica
4. Avaliar: R^2 , RMSE, resíduos, validação leave-one-year-out

CUIDADOS

Correlação não implica causalidade

Relação pode ser **quadrática**: chuva sobe Y até um ponto, depois cai

Atenção a colinearidade entre variáveis climáticas

Curva em **U invertido** entre chuva e produtividade é recorrente em soja: chuva demais na colheita prejudica tanto

Modelos de séries temporais

APLICAÇÃO


Separar **tendência + ciclo + resíduo climático**.

TÉCNICAS

Decomposição aditiva / multiplicativa


Médias móveis

ARIMA (em séries longas o suficiente)




O seguinte exemplo mostra o componente sazonal de uma análise STL usando incidentes de tornado nos Estados Unidos. O componente foi calculado com base na sazonalidade mensal e oscila entre uma contagem alta em Junho e uma contagem baixa em Janeiro. As oscilações aumentam em amplitude ao longo do tempo, o que indica que a variação sazonal na frequência do tornado está aumentando ao longo do tempo.

O seguinte exemplo mostra o componente de tendência de uma análise STL usando incidentes de tornado nos Estados Unidos. O resultado mostra uma tendência geral positiva, o que significa que o número de incidentes de tornado nos Estados Unidos está aumentando com o tempo.



O seguinte exemplo mostra o componente restante de uma análise STL usando incidentes de tornado nos Estados Unidos. Os valores restantes começam relativamente pequenos e se tornam maiores nos anos posteriores, o que indica que a quantidade de ruído nos dados aumentou com o tempo. Os valores restantes plotados também mostram um valor atípico claro em Abril de 2011.



Modelos de produtividade baseados em NDVI

O QUE CAPTURA

Vigor vegetativo: razão entre IV-próximo e luz visível


0,0–0,2 solo exposto · 0,3–0,5 esparsa · 0,6–0,9 densa/saudável

MÉTRICAS DERIVADAS

$NDVI_{máx}$ → biomassa potencial

NDVI integrado (área sob a curva) → produção acumulada

Anomalia de NDVI → indicador de estresse



Graus-dia (GDD) — soma térmica

$$\text{GDD}_{\text{diário}} = \max(0, T_{\text{média}} - T_{\text{base}}) \quad \text{GDD}_{\text{acum}} = \sum \text{GDD}_{\text{diário}}$$

do plantio até a maturação

Soja

$T_{\text{base}} \approx 10\text{ }^{\circ}\text{C}$

Milho

$T_{\text{base}} \approx 10\text{ }^{\circ}\text{C}$

Trigo

$T_{\text{base}} \approx 0\text{--}5\text{ }^{\circ}\text{C}$

Uso no ZARC: GDD acumulado define o ciclo esperado da cultivar e a janela de plantio ideal por município.

Limitação: não captura diretamente o estresse hídrico — GDD pode ser alto mesmo em seca.

Balanço hídrico de Thornthwaite-Mather (1955)

Entrada: P, T, Latitude, CAD



ET_o (Thornthwaite ou Penman-Monteith FAO-56)



P - ET_o (balanço climático mensal/decendial)



P - ET_o > 0 → recarrega o solo até CAD → excedente

P - ET_o < 0 → NAC (negativo acumulado) → solo perde água



ARM = CAD · exp(NAC / CAD)

ET_a = min(ET_o, P + |ΔARM|)

DEF = ET_o - ET_a EXC = P - ET_o - ΔARM (quando > 0)

Perda relativa = $K_y \cdot (1 - ET_a / ET_c)$

K_y de soja na floração ≈ 0,85 — sensibilidade ao déficit varia por cultura e fase

DSSAT — estrutura e aplicação

MÓDULOS PRINCIPAIS

CROPGRO — leguminosas (soja, feijão, amendoim)

CERES — cereais (milho, trigo, arroz, sorgo)

Soil — dinâmica de água, T e N (DSSAT-SWB)

Weather — Tmax, Tmin, P, radiação solar

FLUXO DE SIMULAÇÃO

1. Definir cultivar (coeficientes genéticos)
2. Definir solo (perfil de camadas)
3. Definir manejo (plantio, adubação, irrigação)
4. Rodar dia a dia
5. Saída: fenologia, biomassa, Y, balanço hídrico

AquaCrop (FAO) — fluxo em 4 etapas

01

Cobertura de dossel

CC: crescimento → pico → senescência

02

Transpiração

$Tr = Kcb \cdot CC \cdot ET_o$

03

Biomassa

$B = WP^* \cdot \sum (Tr / ET_o)$

04

Produtividade

$Y = B \cdot HI$ (índice de colheita)

4 ESTRESSES HÍDRICOS

Expansão do dossel (reduz CC)

Fechamento estomático (reduz Tr)

Senescência antecipada (reduz duração)

Ajuste do índice de colheita (reduz HI)

VANTAGEM PARA O PROAGRO

~30 parâmetros vs. >100 no DSSAT. Mais adequado quando os dados são limitados. Estresses térmicos:

WP*; calor/frio na floração reduz HI.

Pipeline típico de predição de produtividade

01 - COLETA

Features

P mensal, Tmax/Tmin, GDD, SPI-3, NDVI médio e pico, altitude, solo, latitude.

02 - PRÉ

Pré-processamento

Normalização, imputação de faltantes, detrending da produtividade.

03 - SPLIT

Treino / teste

Divisão **temporal** (treina passado, testa futuro) ou Leave-One-Region-Out.

04 - TREINO

Modelagem

Random Forest, XGBoost, ou ensemble.

05 - AVAL

Métricas

RMSE, R^2 , rRMSE — atenção a anos extremos.

06 - EXPL

Explicabilidade

SHAP por predição: justifica cada alerta.

A parte mais crítica não é o algoritmo — é o **split de dados**. Divisão aleatória contamina o teste (data leakage); divisão temporal é obrigatória.

SHAP — explicabilidade por predição

Baseado na teoria dos jogos (valores de Shapley)

Para cada predição, mostra **quanto cada variável contribuiu** para desviar o resultado da média

Permite responder: “*por que o modelo previu perda de 30% neste município?*”

Importância para o Proagro: permite justificar alertas de forma transparente e auditável.

EXEMPLO CONCEITUAL

Predição: 1.500 kg/ha (média 3.000)

Variável	Valor	Contribuição
SPI-3	-1,8	-800 kg/ha
NDVI _{pico}	0,45	-400 kg/ha
GDD acum.	baixo	-300 kg/ha

Resumo comparativo detalhado

Modelo	Dado mínimo	Resultado	Interpretab.	Adequação ao Proagro
Regressão Linear	Y + 1–2 var. climáticas	Y estimada	excelente	Linha de base simples
SPI / SPEI	P (+ ETo)	Índice de seca	excelente	Plausibilidade de COPs por seca
Balanço hídrico (T-M)	T, P, CAD, lat.	Déficit / Excedente	alta	Base do ZARC
DSSAT	Clima diário, solo, cultivar, manejo	Y simulada dia a dia	alta	Benchmark — alto custo
AquaCrop	Clima diário, solo, CC	Y baseada em água	alta	Benchmark com menos dados
Random Forest / XGBoost	Clima, NDVI, solo, Y	Y predita + importância	média	Triagem; requer SHAP
CNN-LSTM	Séries temporais	Y predita	baixa	Máxima acurácia, mín. interpretab.

Boas Práticas



Município X · safra

2023/2024 · soja

Fonte	Informação	Resultado
Sicor (COPs)	120 COPs por seca no município	Alta concentração
MERGE (P)	P acum. dez–fev: 280 mm (normal 450)	Déficit de 38%
SPI-3 (jan–mar)	–1,6	Seca severa
NDVI MODIS (fev)	Anomalia = –0,12 (18% abaixo)	Vegetação estressada
ZARC	Apto no decêndio informado	Janela adequada
Random Forest	Y estimada 1 600 kg/ha (média 3 100)	Perda esperada ~48%

Os indicadores convergem → COPs por seca **são consistentes** com as evidências. Mas isso **não dispensa** análise individual: glebas irrigadas ou com solo profundo podem não se justificar.

Sete boas práticas no uso de modelos

Nunca usar um modelo único como critério de decisão — sempre triangular fontes

Documentar pressupostos — qual modelo, dados, período, escala

Reportar incerteza — intervalos de confiança, mapas de variância da krigagem

Validar com dados independentes — não avaliar com os mesmos dados de calibração

Atualizar periodicamente — recalibrar com dados recentes

O que NÃO fazer com modelos de perdas

Usar SPI ou SPEI como critério **binário** de aceite/rejeição de COPs

Aplicar modelo treinado numa região a outra **sem validação**

Tratar produtividade simulada como **verdade** — é estimativa

Ignorar **anos extremos** na avaliação do modelo

Operar modelos de ML **sem explicabilidade** (SHAP/LIME)

O que considerar

MENSAGEM 01

**Nenhum modelo é
suficiente sozinho;**

modelos de baixa frequência;
agroclimáticos sustentam o ZARC;
mecanísticos refinam o
benchmark; ML traz acurácia para
triagem.

MENSAGEM 02

**Incerteza precisa ser
quantificada**

Qualidade das estações é
insuficiente; geoestatística reduz
risco de base; e a
não-estacionariedade desafia
modelos calibrados no passado.

MENSAGEM 03

**Modelos geram alertas,
não veredictos**

Alertas são decisões humanas,
fundamentada em múltiplas
evidências, e padrões estatísticos
não atribuem responsabilidade
individual.